



河南理工大学学报(自然科学版)

Journal of Henan Polytechnic University(Natural Science)

ISSN 1673-9787,CN 41-1384/N

《河南理工大学学报(自然科学版)》网络首发论文

题目: 改进麻雀搜索算法优化的短期电力负荷 CNN-BiLSTM 融合预测模型
作者: 米浩然, 申森林, 卫紫任, 李巍, 李亚楠
收稿日期: 2025-12-26
网络首发日期: 2026-06-10
引用格式: 米浩然, 申森林, 卫紫任, 李巍, 李亚楠. 改进麻雀搜索算法优化的短期电力负荷 CNN-BiLSTM 融合预测模型[J/OL]. 河南理工大学学报(自然科学版). <https://link.cnki.net/urlid/41.1384.N.20260610.1055.004>



网络首发: 在编辑部工作流程中,稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定,且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件,可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定;学术研究成果具有创新性、科学性和先进性,符合编辑部对刊文的录用要求,不存在学术不端行为及其他侵权行为;稿件内容应基本符合国家有关书刊编辑、出版的技术标准,正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性,录用定稿一经发布,不得修改论文题目、作者、机构名称和学术内容,只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约,在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版,以单篇或整期出版形式,在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z),所以签约期刊的网络版上网络首发论文视为正式出版。

改进麻雀搜索算法优化的短期电力负荷 CNN-BiLSTM 融合预测模型

米浩然,申森林,卫紫任,李巍,李亚楠

(国网河南省电力公司焦作供电公司, 河南 焦作 454000)

摘要: 目的 为提高电力负荷预测精度,降低预测难度,进行改进麻雀搜索算法优化的短期电力负荷 CNN-BiLSTM 融合预测模型研究。**方法** 以河南省某地区 110 kV 变电站 2022 年的电力负荷数据为基础,提出一种基于改进麻雀搜索算法优化的卷积神经网络-双向长短期记忆网络(ISSA-CNN-BiLSTM)融合预测模型。首先,以日期信息、气象数据以及相似日负荷数据等构建特征集作为模型的输入变量,并对数据的异常值、缺失值和数据不规范等问题进行预处理。其次,采用 CNN 模型有效提取特征图中连续/非连续数据之间的潜在联系并构造时序序列的特征向量,再基于 BiLSTM 模型对其进行训练及预测。同时利用正余弦策略和柯西变异策略对传统的 SSA 进行强化,实现对模型超参数的自动寻优,得到预测结果。**结果** 仿真结果表明,相比较 LSTM、PSO-LSTM、CNN-LSTM 和 Transformer-BiLSTM 预测模型,ISSA-CNN-BiLSTM 模型的预测误差 MAPE 降低为 1.570 3%,平均绝对误差为 0.427 6,均方根误差为 0.645 3,预测精度得到明显提高。**结论** ISSA-CNN-BiLSTM 融合预测模型能够克服负荷预测随机因素的影响,具有更强的负荷时间相关性捕捉能力和泛化能力,可以为实际电力系统的高效运行和优化调度提供新的思路和方法。

关键词: 短期负荷预测; CNN-BiLSTM 融合模型; 改进麻雀搜索算法; 预测精度

中图分类号: TM715

An improved SSA-optimized CNN-BiLSTM integrated model for short-term electricity load forecasting

Mi Haoran, Shen Senlin, Wei Ziren, Li Wei, Li Yalei

(State Grid Henan Jiaozuo Power Supply Company, Jiaozuo 454000, Henan, China)

Abstract: *Objectives* Accurate power load forecasting is one of the effective means to ensure stable operation of power grid and rational resource allocation. However, due to the high penetration of renewable energy, as well as the influence of meteorological conditions and diversified load structures, the uncertainty and difficulty of power load forecasting have further increased. *Methods* Based on the power load data of a 110kV substation in a certain region of Henan Province in 2022, an ISSA-CNN-BiLSTM integrated forecasting model optimized by an improved sparrow search algorithm (ISSA) was investigated. Firstly, by considering date information, meteorological data, and similar daily load data, a feature set was constructed as input variables for the model and the outliers, missing values and non-standard data formats were preprocessed. Secondly, the CNN model was employed to effectively extract the potential connections between sequential/non-sequential data in the feature map and construct the feature vectors of the time series. Then, BiLSTM model was used for training and prediction and the traditional SSA was enhanced by incorporating sine-cosine and Cauchy mutation strategies to achieve automatic optimization of model hyperparameters. *Results* Compared to the LSTM, PSO-LSTM, CNN-LSTM and Transformer-BiLSTM forecasting models, the ISSA-CNN-BiLSTM model exhibited the lower forecasting error, with the mean absolute percentage error (MAPE) as low as 1.570 3%, mean absolute error (MAE) of 0.427 6 and root mean square error (RMSE) of 0.645 3, which indicated a significant improvement in forecasting accuracy. *Conclusions* The ISSA-CNN-BiLSTM integrated forecasting model effectively mitigates the impact of stochastic factors in load forecasting. It exhibits enhanced capability in capturing temporal load correlations and possesses stronger generalization performance. This model can provide novel insights and methodologies for the efficient operation and optimal scheduling of actual power systems.

收稿日期: 2025-12-26; 修回日期: 2026-04-28

基金项目: 国网河南省电力公司科技项目 (5217C0250001)

第一作者简介: 米浩然 (1994—), 女, 河南开封人, 工程师, 主要从事电网运行方式分析的研究工作。Email: 18623705066@163.com

Keywords: short-term load forecasting; CNN-BiLSTM fusion model; ISSA; prediction accuracy

0 引言

为保障电网平稳运行和资源合理分配,减少运行过程中的过载隐患和能源损耗,开展电力负荷精准预测显得尤为重要^[1]。随着电动汽车和分布式电源等新兴技术大规模接入与应用,电力负荷结构日趋复杂化和多样化,负荷预测中强随机性与间歇性等不确定因素显著增强,进一步增大了预测难度^[2]。

短期电力负荷预测主要对未来一天至数周内的用电需求进行量化预估,通过快速响应实际运行需求,缓解配电网中的负荷中断、供需失衡风险与电力短缺等问题^[3]。目前,对短期电力负荷的预测研究主要包括两类方法:一类是传统的数学统计方法如回归分析法、卡尔曼滤波法和灰色理论等,另一类是基于人工智能的预测方法如人工神经网络、深度学习、相关向量机和混合模型等^[4-6]。随着人工智能理论与计算技术的快速发展迭代以及负荷影响因素复杂多样化的特点,基于人工神经网络的短期电力负荷预测成为广大学者的研究热点。文献[7]利用鲸鱼优化算法对 BiLSTM 网络的超参数进行优化选择并用于短期电力负荷预测,该模型可以全面捕捉电力负荷数据中的时间序列特征,提高了预测准确性;文献[8]通过引入自动相关函数选择最佳输入特征,并利用灰狼算法优化模型参数,建立了 AS-GCLSSVM 混合预测模型;文献[9]将 K-means 聚类 and K-nearest neighbors (KNN)分类相结合,构造考虑假期效应的短期负荷预测模型,预测精度提高较大;在文献[10]中,作者基于两阶段特征提取方法,给出了一种新的短期负荷预测混合模型,结合 iTransformer 模型、时间卷积网络和多层感知器对短期负荷进行准确预测;文献[11]讨论了具有双阶段注意力机制的 LSTM 预测模型,第一阶段利用基于特征注意力的编码器计算输入特征与电力负荷的相关性,第二阶段构建基于特征注意力的解码器充分挖掘时间依赖性,并通过开放数据集验证了该模型在点预测和概率预测的有效性和准确性;文献[12]结合 LSTM 和卷积神经网络 CNN 两种模型的优点,构造了并行 LSTM-CNN 深度学习模型进行短期电力负荷预测,取得了较好的预测效果。

在短期电力负荷预测研究中,现有文献已经构建和应用了多种神经网络架构,然而各类基础模型均存在其固有的优势和相应的局限性。本文采用 ISSA-CNN-BiLSTM 融合模型对短期电力负荷进行预测,该模型有效融合了 CNN 的强大特征提取能力和 BiLSTM 的高效处理序列数据复杂交互关系能力,同时利用正余弦策略和柯西变异策略进一步强化传统 SSA 算法,实现对模型的主要超参数自动寻优,有效提升模型的训练效率和预测精度。

1 预测模型基本原理

1.1 卷积神经网络 CNN

CNN 一般由卷积层、池化层和全连接层构成,如图 1 所示。卷积层利用卷积核对输入数据的局部加权求和,并借助非线性激活函数实现特征映射,有效捕获数据中的局部依赖模式与结构特征。池化层主要对卷积层的输出进行采样,减小数据规模,提高模型的收敛速度和鲁棒性。全连接层通过反向传播算法调整权重和偏置参数,对前层提取的高维抽象特征全局整合和线性变换,并映射到目标维度的输出空间,从而完成最终的分类或回归等任务^[13]。与其他深度学习网络相比,CNN 能够通过多层卷积与池化操作,从输入数据中高效提取局部特征,捕捉空间信息的相关性,为时序建模提供有效的特征表示。卷积和池化计算公式为^[14]

$$\begin{cases} \phi_j^l = f(\phi_{t-1} \times k_j^l), j \in J \\ p_j^{l+1} = \max(\phi_j^l(t)), j \in J \end{cases}, \quad (1)$$

式中: f 、 l 和 J 分别为激活函数、卷积层数和滤波器类型; $\phi_j^l(t)$ 、 k_j^l 和 p_j^{l+1} 分别为上一卷积层的特征映射、每个滤波器输出值和输出特征维度; ϕ_{t-1} 为第 $t-1$ 个输出; $\max(\)$ 为最大池化操作。




图 1 CNN 模型结构图

Fig. 1 Structure of CNN model

1.2 双向长短期记忆网络 BiLSTM

BiLSTM 网络通过结合正向和逆向两个 LSTM 对输入数据进行处理，形成双向的信息交互机制，如图 2 所示。在预测模型训练过程中，BiLSTM 网络可以使当前时间节点的输出充分融合正逆向两个方向的序列信息，更加全面捕捉序列中的特征信息。特别是在负荷预测中，能够有效建模负荷序列在正向和逆向两个方向上的长短期时序依赖，从而更全面地挖掘数据中隐含的动态规律与高阶特征，显著提升短期负荷预测的精度与稳定性^[15]。




图 2 BiLSTM 模型结构图

Fig. 2 Structure of BiLSTM model

BiLSTM 网络内部的状态更新公式^[16]为

$$\begin{cases} f_t = \sigma(W_f \times [\mathbf{h}_{t-1}, \mathbf{x}_t] + b_f) \\ i_t = \sigma(W_i \times [\mathbf{h}_{t-1}, \mathbf{x}_t] + b_i) \\ O_t = \sigma(W_o \times [\mathbf{h}_{t-1}, \mathbf{x}_t] + b_o) \\ \tilde{C}_t = \tanh(W_c \times [\mathbf{h}_{t-1}, \mathbf{x}_t] + b_c) \\ C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t \\ h_t = O_t \times \tanh(C_t) \end{cases}, \quad (2)$$

式中： f_t 、 i_t 和 O_t 分别为遗忘门、输入门和输出门； $\mathbf{x}_t$ 和 $\mathbf{h}_t$ 分别为输入向量和输出向量； C_t 和 $\tilde{C}_t$ 分别为当前细胞状态和候选细胞状态； W_f 、 W_i 、 W_o 和 b_f 、 b_i 、 b_o 分别为遗忘门、输入门和输出门的权重矩阵及偏置； σ 为 sigmoid 函数。

1.3 改进的麻雀搜索算法

在文献[17]基础上，本文将正余弦策略和柯西变异策略相结合对传统 SSA 进行改进。

1.3.1 折射反向学习机制初始化麻雀种群

反向学习机制是一种基于对称搜索的优化方法，在解空间中为当前候选解构造对应的对称解（即反向

解），通过并行评估原始解与反向解，有效拓展搜索过程，增加发现更优解的可能性，显著增强算法的全局搜索能力。但该机制在寻优后期容易陷入早熟收敛，通过引入折射原理可以有效降低过早收敛的概率，折射反向学习机制的基本原理如图 3 所示^[18]。




图 3 折射反向学习机制原理图

Fig. 3 Schematic diagram of reverse learning with refraction principle

图 3 中， l ， u ， O 分别为寻优范围的最小值、最大值和中间值； α ， β 分别为射角和折射角； x ， x^* 分别为麻雀的当前位置和折射反向位置； h ， h^* 分别为入射光线和折射光线的长度。根据中线几何关系和折射率定义，有

$$\begin{cases} \sin \alpha = \frac{\frac{(l+u)}{2} - x}{h} \\ \sin \beta = \frac{x^* - \frac{(l+u)}{2}}{h^*} \\ n = \frac{h^* \left(\frac{(l+u)}{2} - x \right)}{h \left(x^* - \frac{(l+u)}{2} \right)} \end{cases} \quad (3)$$

令缩放因子 $k = h/h^*$ ，折射率 $n = 1$ 时，有

$$x_{i,j}^* = \frac{l_j + u_j}{2} + \frac{l_j + u_j}{2k} - \frac{x_{i,j}}{k}, \quad (4)$$

式中： $x_{i,j}$ ， $x_{i,j}^*$ 分别为种群中第 i 只麻雀在 j 维的位置及其折射反向位置； l_j ， u_j 分别为搜索空间第 j 维的最小值和最大值；

1.3.2 正余弦策略优化麻雀位置更新规则

引入正余弦振荡模型对发现者位置进行动态更新，利用其周期性的波动特性维持种群中探索个体的行为多样性，从而显著增强 SSA 算法的全局探索能力，并有效降低陷入局部最优的风险。根据文献[19]可知，步长搜索因子 r_1 为

$$r_1 = \lambda \times \left(1 - \left(\frac{\vartheta}{Iter_{max}} \right)^\eta \right)^{\frac{1}{\eta}}, \quad (5)$$

式中： λ 为常数，本文取 $\lambda = 1$ ； ϑ 为迭代次数； $\eta \geq 1$ 为调节系数； $Iter_{max}$ 为最大迭代次数。

针对传统位置更新策略对个体当前位置依赖度过高的问题，引入非线性时变权重因子 ω ，动态调节历史位置信息在更新过程中的贡献度。迭代前期使 ω 保持较小权重，弱化当前位置的牵引，强化全局探索能力；迭代后期逐步增大 ω ，引导种群加速向最优区域收敛，提升算法的整体寻优性能。

$$\omega = \frac{e^{\frac{\vartheta}{Iter_{max}} - 1}}{e - 1}. \quad (6)$$

基于上述机制，对发现者位置更新策略进行重构，

$$X_{i,j}^{\vartheta+1} = \begin{cases} \omega \cdot X_{i,j}^{\vartheta} + r_1 \cdot \sin r_2 \cdot |r_3 \cdot X_{best} - X_{i,j}^{\vartheta}|, & R_2 < S_{\vartheta} \\ \omega \cdot X_{i,j}^{\vartheta} + r_1 \cdot \cos r_2 \cdot |r_3 \cdot X_{best} - X_{i,j}^{\vartheta}|, & R_2 \geq S_{\vartheta} \end{cases}, \quad (7)$$

式中： $X_{i,j}^{\vartheta}$ 为迭代次数 ϑ 下第 i 麻雀在 j 维位置； X_{best} 为麻雀当前最优位置； R_2 ， S_{ϑ} 分别为预警值和安全值； r_2 ， r_3 为 $[0, 2\pi]$ 的随机数，决定麻雀的移动距离和控制最优个体对后一位置的影响程度。

1.3.3 柯西变异策略提高全局寻优能力

在麻雀搜索算法中,追随者倾向于聚集在觅食效果较好的发现者周围,这一机制容易引发个体间对优质食物源的竞争,部分追随者可能通过竞争转变为发现者。该过程将导致种群中大多数个体迅速集中于少数区域,使搜索多样性过早丧失,从而显著增加算法陷入局部最优的风险。本文引入柯西变异策略优化追随者的位置更新,提升全局寻优能力。优化后的追随者位置更新为

$$X_{i,j}^{\theta+1} = X_{best}(\theta) + Cauchy(0,1) \oplus X_{best}(\theta), \quad (8)$$

式中: $Cauchy(0,1)$ 为标准柯西分布函数,一般表示为 $f(x) = \frac{1}{\pi}(\frac{1}{x^2+1})$; $\oplus$ 表示相乘。

2 基于 ISSA-CNN-BiLSTM 的短期电力负荷预测模型

2.1 预测模型建立

为了提高短期电力负荷预测的准确性,本文将 CNN 和 BiLSTM 结合,建立 CNN-BiLSTM 融合预测模型,充分发挥 CNN 在时间序列短时序特征提取和 BiLSTM 在长时序特征提取方面的优势。同时,考虑到 CNN-BiLSTM 网络结构的参数选择对负荷预测性能的影响,利用改进的麻雀搜索算法对模型的关键参数进行自动寻优。ISSA-CNN-BiLSTM 融合预测模型的整体结构如图 4 所示。

该融合预测模型中的 CNN 模块主要由 2 个卷积层和 2 个池化层构成,卷积层通过卷积核在负荷序列上滑动,对负荷序列的局部片段进行特征提取,生成高阶特征表示;池化层在此基础上执行最大池化操作,实现特征降维与关键信息增强。特征序列随后被送入 BiLSTM 模块,其主要由 LSTM 层、Dropout 层和全连接层组成。LSTM 层负责对 CNN 提取的有效特征进行长期时序依赖建模,并通过后续的 Dropout 层与全连接层输出最终预测结果。Dropout 层防止模型过拟合,全连接层输出预测点的负荷值。ISSA 算法对 CNN-BiLSTM 融合模型的关键参数进行自动寻优,获得模型的最优参数配置,然后赋值给 CNN-BiLSTM 模型进行负荷预测。




图 4 ISSA-CNN-BiLSTM 融合预测模型整体结构图

Fig. 4 Overall structure diagram of ISSA-CNN-BiLSTM

2.2 预测模型预测流程

ISSA-CNN-BiLSTM 融合模型的预测流程为:

(1) 考虑到负荷数据通常受到气象条件、日期类型和历史负荷等因素的影响,具有较强的时序特征。为了提高数据的稳定性和准确性,首先对原始数据进行预处理和归一化,其中主要包括异常数据清洗、缺失数据插值处理、平滑处理等,同时构建模型的特征集。

(2) 将处理后的数据划分为训练集和验证集,分别用于模型构建与性能评估。训练集通过对模型参数进行学习拟合,构建短期电力负荷预测模型,验证集用于模型选择与超参数调优,评估模型预测的有效性和准确性。其中,利用 CNN 的卷积层有效提取输入数据的特征信息,并通过池化层将其输入至 BiLSTM 模块进行训练。

(3) 初始化 ISSA 算法并对 CNN-BiLSTM 模型的关键参数如学习率、正规化系数和隐含层节点等

进行自动寻优，选取均方根误差 $RMSE$ 作为适应度函数，得到最优适应度值和最佳位置，建立预测模型。

(4) 采用训练后的 ISSA-CNN-BiLSTM 融合模型进行预测，输出各个时刻的预测值，并对预测值进行反归一化处理，得到负荷预测的最终结果。

2.3 预测模型精度评价指标

本文选择平均绝对误差 MAE 、均方根误差 $RMSE$ 和平均绝对百分比误差 $MAPE$ 作为预测精度的评价指标^[20]。各指标数值越小，表明模型的预测精度越高。

$$K_{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (9)$$

$$K_{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (10)$$

$$K_{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|, \quad (11)$$

式中： y_i ， $\hat{y}_i$ 分别为负荷的实际值和预测值； n 为预测样本数量。

3 算例分析

3.1 负荷数据集选取

为验证所提预测模型的有效性和准确性，选取河南省某地区的历史负荷数据作为数据集，同时收集同时期该地区的温湿度、辐射强度和风速等气象数据。负荷数据的采集周期设定为 15 min，选取 2022 年 1 月 1 日—2022 年 12 月 31 日的样本数据进行实验。CNN-BiLSTM 融合预测模型共有 5 个可优化参数，即正规化系数、学习率和 3 个隐含层最佳神经元个数。ISSA 优化算法参数设置主要结合文献[3,14]中的经验设置，考虑模型的预测精度和收敛速度平衡，通过测试具体设置如下：种群大小为 30，最大迭代次数为 20，发现者 PD 比例占种群的 30%，追随者占 70%，安全阈值 $ST=0.8$ 。在种群中选取 10%麻雀作为预警者 SD。

3.2 ISSA 优化算法性能测试

为评估 ISSA 算法的全局搜索能力和收敛性能，选取粒子群优化算法 (PSO)、灰狼优化算法 (GWO)、SSA 算法和本文优化算法进行对比分析，各算法参数设置见表 1。选用单峰函数 Schwefel's 2.22 作为测试函数，定义域为 $[-10, 10]$ ，最优解为 0。4 种算法统一设置种群为 100，维度为 30，最大迭代次数为 1000，得到的收敛曲线如图 5 所示。

表 1 4 种优化算法的主要参数设置

Tab. 1 Main parameter settings for four optimization algorithms

优化算法	参数设置
PSO	$\omega \in [0.2, 0.9]$, $c_1 = c_2 = 1.5$
GWO	$\alpha \in [0, 2]$, $r_1, r_2 \in [0, 1]$
SSA	$ST = 0.8$, $PD = 0.3$, $SD = 0.1$
ISSA	$ST = 0.8$, $PD = 0.3$, $SD = 0.1$, $\eta = 1.5$




图 5 测试函数下 4 种优化算法的收敛曲线

Fig. 5 Convergence curves of four optimization algorithms under test functions

由图 5 可知, ISSA 算法在收敛性能和精度方面得到显著提升, 能够有效逼近理论最优解, 比 PSO、GWO 及 SSA 算法优势明显。同时, 验证了折射反向学习策略能够降低 SSA 算法在寻优后期进入早熟收敛的可能性, 正余弦策略和柯西变异策略具有跳出局部最优和快速搜索能力, 提高了算法的收敛速度和精度。

3.3 负荷预测结果及对比分析

为了验证本文模型的负荷预测效果与泛化功能, 采用 2 组数据集进行对比实验。第 1 组数据集取 2022 年 1 月 1 日—2022 年 1 月 7 日的周负荷和气象数据为样本, 另一组数据集共采集 1 440 个电力负荷数据, 涵盖 2022 年 1 月 1 日—2022 年 1 月 15 日的气象数据和电力负荷, 同时将 2 组数据集按 7:3 划分为训练集和测试集, 滚动多步进行预测。ISSA-CNN-BiLSTM 模型中超参数的取值范围和利用 ISSA 算法优化得到的最优值见表 2 所示。本文仿真实验利用 MATLAB R2022b 编程软件进行分析, 得到的第 1 组数据集预测结果如图 6~7 所示。

表 2 预测模型超参数寻优范围及最优值
Tab. 2 Optimization range and optimal value of model hyperparameters

待优化超参数	寻优范围	最优值
学习率	0.001~0.01	0.004 2
正则化系数	0.000 1~0.01	0.000 1
隐含层层数	1~5	3
隐含层神经元个数	10~300	[3 003 027]




图 6 CNN-BiLSTM 模型预测结果

Fig. 6 Forecasting results for CNN-BiLSTM




图 7 ISSA 优化后 CNN-BiLSTM 模型预测结果

Fig. 7 Forecasting results of CNN-BiLSTM optimized by ISSA

综合图 6~7 可以看出, 利用经 ISSA 优化后参数构建的预测模型, 周负荷的预测结果与实际值更为接近, $RMSE$ 由 1.204 3 减至 0.266 56, 预测曲线与实际曲线几乎完全重合。因此, 本文模型可以有效预测短期内日负荷量未来的变化趋势, 精准把握负荷变化规律。

选择 LSTM、PSO-LSTM、CNN-LSTM 和 Transformer-BiLSTM 模型对比分析。通过对第 2 组数据集进行电力负荷短期预测, 结果如图 8 所示。根据仿真结果计算上述模型的 K_{MAE} , K_{RMSE} , K_{MAPE} , 预测误差结果如表 3 所示。




图 8 本文模型与其它模型预测结果对比

Fig. 8 Comparison of prediction results of the proposed model with other models

由图 8 可知, 5 种模型的负荷预测值和实际值的曲线基本一致, 但各模型的预测精度存在一定差异。电力负荷存在较强的非线性和非平稳性, 不同时间段的负荷数据差异较大, 传统的 LSTM 模型虽预测趋势与

实际负荷数据大体相同,采用单向信息学习模型对复杂数据的学习能力较弱,导致预测结果与实际值相差较大,特别是负荷处于波峰或波谷时,预测精度较差。PSO-LSTM 和 CNN-LSTM 虽在一定程度上克服了 LSTM 模型存在的局限性,但二者的预测表现各有所长。如 PSO 算法对 LSTM 模型预测性能的提升有限,特别是在电力负荷剧烈波动时期,预测精度并不理想;CNN-LSTM 预测精度和拟合度有明显提高,但由于模型超参数数量多,训练时间长且对计算资源要求较高,同时可能带来梯度消失或爆炸问题。Transformer-BiLSTM 模型利用多头注意力机制可以同时关注不同维度的负荷特征,对长周期性的负荷序列有优势,但在小样本场景下极易过拟合,对负荷序列中的非平稳波动适应性有限。本文利用 ISSA 优化算法对 CNN-BiLSTM 模型的网络结构参数进行全局优化搜索并确定最佳参数组合,在防止过拟合和局部特征提取上更具优势,能够显著提升 CNN-BiLSTM 模型的预测精度和泛化能力,无论是在负荷波动频繁区域还是波动较小的平滑区域都表现良好。

表 3 各模型预测误差对比
Tab. 3 Comparison of prediction errors of each model

预测模型	K_{MAE}	K_{RMSE}	$K_{MAPE}/\%$
LSTM	3.223 3	4.010 9	11.605 8
PSO-LSTM	1.084 6	1.384 9	4.002 9
CNN-LSTM	0.880 4	1.191 2	3.356 2
Transformer-BiLSTM	0.531 7	0.798 1	2.632 5
ISSA-CNN-BiLSTM	0.427 6	0.645 3	1.570 3

由表 3 可知,本 ISSA-CNN-BiLSTM 融合预测模型与 LSTM、PSO-LSTM、CNN-LSTM 和 Transformer-BiLSTM 模型相比, K_{MAE} 分别降低了 2.795 7, 0.657, 0.452 8, 0.104 1; K_{RMSE} 分别降低了 3.365 6, 0.739 6, 0.545 9, 0.152 8; K_{MAPE} 分别降低了 10.035 5%, 2.432 6%, 1.785 9%, 1.062 2%。由此可见,ISSA-CNN-BiLSTM 融合预测模型的预测误差明显小于其他模型,预测精度显著提高。综上,ISSA-CNN-BiLSTM 融合预测模型将历史用电负荷及相关影响因素深度集成于神经网络架构,有效捕捉负荷时序演变的内在规律,显著提升对未来用电负荷的预测精度。

4 结 论

(1) 针对传统 SSA 算法容易陷入局部最优和精度不高的问题,采用折射反向学习机制、正余弦策略和柯西变异策略分别对麻雀种群初始化、寻优能力和捕食范围进行优化,从而提高 SSA 算法的全局和局部寻优能力及收敛速度。

(2) 结合 CNN 提取局部特征的优势和 BiLSTM 双向时序建模能力,建立 CNN-BiLSTM 融合预测模型,并利用 ISSA 算法对 CNN-BiLSTM 模型的超参数进行自动寻优,并构建 ISSA-CNN-BiLSTM 模型。与传统单一模型相比,本文模型能有效捕捉更多负荷波动规律,特别是在负荷剧烈波动时段响应速度有所提升。

(3) ISSA-CNN-BiLSTM 融合模型预测精度高,各项评价指标均优于其他模型,能够更准确反映实际负荷数据的变化特点。ISSA-CNN-BiLSTM 融合模型数据集在时间尺度上存在一定局限,比传统预测模型计算复杂度高,探讨其在长期演变场景下的适应性、开发轻量化的预测模型是后续研究的重点方向。

参考文献

[1] 许世欣, 李雯婷, 彭道刚, 等. 基于二次模态分解与 Informer-BiLSTM 的电力负荷预测[J]. 浙江电力, 2025, 44(10): 55-68.
XU S X, LI W T, PENG D G, et al. Power load forecasting based on SMD-informer-BiLSTM[J]. Zhejiang Electric Power, 2025, 44(10): 55-68.

[2] 唐竹, 肖宇航, 郭淳, 等. 基于 CEEMDAN 模态分解和 TCN-BiGRU 的短期电力负荷预测[J]. 智慧电力, 2024, 52(12): 59-64.
TANG Z, XIAO Y H, GUO C, et al. Short-term electricity load forecasting based on CEEMDAN decomposition and TCN-BiGRU model[J]. Smart Power, 2024, 52(12): 59-64.

[3] 赵婧宇, 池越, 周亚同. 基于 SSA-LSTM 模型的短期电力负荷预测[J]. 电工电能新技术, 2022, 41(6): 71-79.
ZHAO J Y, CHI Y, ZHOU Y T. Short-term load forecasting based on SSA-LSTM model[J]. Advanced Technology of Electrical

Engineering and Energy, 2022, 41(6): 71-79.

- [4] 杨佳泽, 王灿, 王增平. 新型电力系统背景下的智能负荷预测算法研究综述[J]. 华北电力大学学报(自然科学版), 2025, 52(3): 54-67.
- YANG J Z, WANG C, WANG Z P. Review on intelligent load forecasting algorithms for the new-type power system[J]. Journal of North China Electric Power University (Natural Science Edition), 2025, 52(3): 54-67.
- [5] 张碧莹. 基于 SSA-CNN-LSTM 模型的短期电力负荷预测[D]. 沈阳: 沈阳农业大学, 2023.
- ZHANG B Y. Short-term power load forecasting based on SSA-CNN-LSTM model[D]. Shenyang: Shenyang Agricultural University, 2023.
- [6] AQUILA G, MORAIS L B S, DE FARIA V A D, et al. An overview of short-term load forecasting for electricity systems operational planning: Machine learning methods and the Brazilian experience[J]. Energies, 2023, 16(21): 7444.
- [7] ZHAO H X, ZHOU Z L, ZHANG P Z. Forecasting of the short-term electricity load based on WOA-BiLSTM[J]. International Journal of Pattern Recognition and Artificial Intelligence, 2023, 37(11): 2359018.
- [8] YANG A L, LI W D, YANG X. Short-term electricity load forecasting based on feature selection and least squares support vector machines[J]. Knowledge-Based Systems, 2019, 163: 159-173.
- [9] HNIN S W, KARNJANA J, KOHDA Y, et al. A hybrid K-means and KNN approach for enhanced short-term load forecasting incorporating holiday effects[J]. Energy Reports, 2024, 12: 5942-5959.
- [10] HUANG Z W, YI Y W. Short-term load forecasting for regional smart energy systems based on two-stage feature extraction and hybrid inverted transformer[J]. Sustainability, 2024, 16(17): 7613.
- [11] LIN J, MA J, ZHU J G, et al. Short-term load forecasting based on LSTM networks considering attention mechanism[J]. International Journal of Electrical Power & Energy Systems, 2022, 137: 107818.
- [12] FARSI B, AMAYRI M, BOUGUILA N, et al. On short-term load forecasting using machine learning techniques and a novel parallel deep LSTM-CNN approach[J]. IEEE Access, 2021, 9: 31191-31212.
- [13] 王潇添, 李泽林, 詹莹, 等. 基于 KOA 驱动的 VMD-CNN-BiGRU-Attention 光伏功率组合预测模型研究[J]. 太阳能学报, 2025, <https://doi.org/10.19912/j.0254-0096.tynxb.2025-0114>.
- WANG X T, LI Z L, ZHAN Y, et al. KOA-driven VMD-CNN-BiGRUAttention model sresearch for combined prediction of PV power output [J]. Acta Energiae Solaris Sinica, 2025, <https://doi.org/10.19912/j.0254-0096.tynxb.2025-0114>.
- [14] 童宇轩, 李灿, 金超. 基于改进麻雀搜索算法的短期光伏功率 CNN-BiLSTM 预测模型[J]. 黑龙江电力, 2025, 47(4): 315-320, 376.
- TONG Y X, LI C, JIN C. Short-term CNN-BiLSTM prediction model of photovoltaic power based on improved sparrow search algorithm[J]. Heilongjiang Electric Power, 2025, 47(4): 315-320, 376.
- [15] 李振华, 姜雨菲, 杜锋, 等. 基于 LSTM-Transformer 模型的突水条件下矿井涌水量预测[J]. 河南理工大学学报(自然科学版), 2026, 45(1): 77-85.
- LI Z H, JIANG Y F, DU F, et al. Prediction of mine water inflow under water-inrush conditions based on a LSTM-Transformer model[J]. Journal of Henan Polytechnic University (Natural Science), 2026, 45(1): 77-85.
- [16] 余德泳, 刘蓉晖. 极端天气事件下基于 BiLSTM-KDE-QR 模型的多类型用户短期负荷预测[J]. 上海电力大学学报, 2026, 42(2): 151-159.
- YU D Y, LIU R H. Short-term load forecasting for multi-type customers based on BiLSTM-KDE-QR model under extreme weather[J]. Journal of Shanghai University of Electric Power, 2026, 42(2): 151-159.
- [17] 李爱莲, 全凌翔, 崔桂梅, 等. 融合正余弦和柯西变异的麻雀搜索算法[J]. 计算机工程与应用, 2022, 58(3): 91-99.
- LI A L, QUAN L X, CUI G M, et al. Sparrow search algorithm combining sine-cosine and cauchy mutation[J]. Computer Engineering and Applications, 2022, 58(3): 91-99.
- [18] 邵鹏, 吴志健, 周炫余, 等. 基于折射原理反向学习模型的改进粒子群算法[J]. 电子学报, 2015, 43(11): 2137-2144.
- SHAO P, WU Z J, ZHOU X Y, et al. Improved particle swarm optimization algorithm based on opposite learning of refraction[J]. Acta Electronica Sinica, 2015, 43(11): 2137-2144.
- [19] 高雷阜, 荣雪娇. 融合递减策略与 Fuch 混沌机制的改进 YSGA 算法[J]. 计算机科学与探索, 2021, 15(3): 564-576.
- GAO L F, RONG X J. Improved YSGA algorithm combining declining strategy and fuch chaotic mechanism[J]. Journal of

Frontiers of Computer Science & Technology, 2021, 15(3): 564-576.

[20] 王瑞, 李虹锐, 逯静, 等. 基于 VMD-LILGWO-LSSVM 短期风电功率预测[J]. 河南理工大学学报(自然科学版), 2024, 43(2): 128-136.

WANG R, LI H R, LU J, et al. Short-term wind power prediction based on VMD-LILGWO-LSSVM[J]. Journal of Henan Polytechnic University (Natural Science), 2024, 43(2): 128-136.

责任编辑 郭倩倩

